

گزارش فاز دوم: توسعه، ارزیابی و استقرار سیستم تشخیص شیء هوشمند

دانشگاه: صنعتی خواجه نصیرالدین طوسی

درس: هوش مصنوعی

استاد: خانم دکتر پیشگو

دانشجویان: شمیم صداقت تیموری، مهدی سلمان

مسیر انتخابی: مسیر ۴ - بینایی ماشین (Object Detection)

۱. مقدمه و اهداف فاز دوم

پس از اجرای موفقیت آمیز فاز نخست پروژه که به آماده سازی، پاک سازی و فرمت بندی دیتاست پیچیده KITTI اختصاص داشت، فاز دوم با هدف توسعه یک سیستم بینایی ماشین (Computer Vision) کاربردی و بلادرنگ آغاز گردید. در این فاز، هدف تنها اجرای یک مدل آماده نبود؛ بلکه بررسی مسیر تکامل شبکه های عصبی پیچیده، شناسایی نقاط ضعف در فرآیند آموزش، و اعمال تکنیک های مهندسی برای رفع آن ها مد نظر قرار گرفت.

اهداف اصلی این فاز به شرح زیر پیاده سازی شدند:

- آموزش و ارزیابی مدل های تشخیص شیء: پیاده سازی سه رویکرد متفاوت (از آموزش صفر تا معماری های پیشرفته) برای بررسی تاثیر تکنیک هایی نظیر یادگیری انتقالی. (Transfer Learning)
- تحلیل علمی چالش ها: شناسایی دقیق مشکلاتی نظیر بیش برآزش (Overfitting) و عدم تعادل کلاس ها (Class Imbalance) از طریق تحلیل نمودارهای ارزیابی.
- استقرار و کاربردی سازی (Deployment): توسعه یک رابط کاربری تعاملی تحت وب برای استفاده نهایی از مدل در سناریوهای واقعی.
- معماری سیستم و MLOps: استفاده از محیط ایزوله داکر (Docker) برای استاندارد سازی فرآیند آموزش و تست.

۲. مدل اول: آموزش از پایه (YOLOv8n - Baseline Model)


به عنوان اولین گام در مسیر حل مسئله، تصمیم بر آن شد تا یک مدل پایه (Baseline) ایجاد گردد. ایجاد مدل پایه در پروژه های یادگیری عمیق، معیاری برای سنجش میزان اثربخشی تکنیک های پیشرفته تر در مراحل بعدی فراهم می کند.

۲-۱. استراتژی و پیکربندی شبکه


برای این مدل، از سبک ترین معماری خانواده یولو یعنی YOLOv8 Nano استفاده شد. مهم ترین ویژگی این مرحله، عدم استفاده از وزن های از پیش آموزش دیده (Pre-trained Weights) بود. شبکه کاملاً از صفر (Scratch) و با وزن های تصادفی مقداردهی اولیه شد تا توانایی خام مدل در استخراج ویژگی های بصری (مانند لبه ها، بافت ها و اشکال خودروها و عابرین) صرفاً بر اساس تصاویر محدود دیتاست KITTI سنجیده شود.

۲-۲. تحلیل رفتار مدل و متریک‌های ارزیابی

نتایج به دست آمده از آموزش مدل پایه به وضوح پدیده Underfitting (کم‌برازش) را نشان داد. به دلیل کوچک بودن ظرفیت شبکه (Nano) و عدم وجود دانش قبلی، مدل نتوانست الگوهای پیچیده تصاویر ترافیکی را به درستی درک کند. دقت نهایی مدل (mAP50) در این مرحله در حدود ۳۴ درصد متوقف شد که برای کاربردهای خودران غیرقابل قبول است.



تحلیل منحنی Precision-Recall: همان‌طور که در نمودار بالا مشاهده می‌شود، مساحت زیر نمودار (AUC) به شدت پایین است. افت سریع این منحنی نشان‌دهنده ناتوانی مدل در حفظ تعادل میان دقت (Precision) و پوشش (Recall) است؛ به این معنا که مدل یا اشیاء را پیدا نمی‌کند، یا در صورت پیدا کردن، برچسب اشتباهی به آن‌ها اختصاص می‌دهد. این ضعف در کلاس‌های اقلیت مانند عابر پیاده (Pedestrian) بسیار مشهودتر است.



تحلیل منحنی F1-Score: نمودار F1-Score که میانگین هارمونیک دقت و پوشش را نشان می‌دهد، تایید می‌کند که بالاترین امتیاز مدل در آستانه‌های اطمینان (Confidence) بسیار پایین رخ داده است. این یعنی مدل حتی به پیش‌بینی‌های درست خود نیز اطمینان کافی ندارد.

۲-۳. تحلیل ماتریس درهم‌ریختگی (Confusion Matrix)

برای درک بهتر خطاهای طبقه‌بندی، ماتریس درهم‌ریختگی مدل مورد بررسی قرار گرفت:



تحلیل این ماتریس دو ضعف عمده شبکه خام را آشکار ساخت:

۱. **خطای پس‌زمینه (Background False Positives/Negatives):** درصد بالایی از اشیاء موجود در تصویر توسط شبکه به عنوان پس‌زمینه تشخیص داده شده‌اند (اشیاء نادیده گرفته شده). همچنین در مواردی، بخش‌هایی از خیابان یا درختان به اشتباه به عنوان وسایل نقلیه تشخیص داده شده‌اند.

۲. **عدم تفکیک کلاس‌های مشابه:** مدل در تمایز قائل شدن بین کلاس‌های دارای ویژگی‌های ظاهری مشابه (مانند Van و Car) دچار سردرگمی شدید است.

۲-۴. بررسی کیفی نتایج (Validation Batches)

بررسی چشمی خروجی‌های مدل بر روی داده‌های اعتبارسنجی (Validation)، تحلیل‌های کمی را تایید می‌کند:



(تصویر بالا: لیبل‌های واقعی (Ground Truth))



(تصویر بالا: پیش‌بینی‌های مدل پایه)

با مقایسه دو تصویر بالا مشخص می‌شود که کادرهای محدودکننده (Bounding Boxes) رسم شده توسط مدل پایه، دقت مکانی لازم را ندارند. (Localization Error) بسیاری از خودروهای در فواصل دور نادیده گرفته شده‌اند و عابرین پیاده به دلیل ابعاد کوچک‌تر در تصویر، به طور کامل از دید شبکه پنهان مانده‌اند.

نتیجه‌گیری مدل اول: آزمون مدل پایه اثبات کرد که آموزش یک شبکه از صفر بر روی یک دیتاست با چالش‌های دنیای واقعی (محیط‌های شلوغ، نورهای متفاوت و اشیاء روی هم افتاده) نیازمند منابع محاسباتی عظیم و دیتاستی بسیار بزرگتر


از KITTI است. این نتیجه، ضرورت استفاده از تکنیک یادگیری انتقالی (Transfer Learning) را برای ادامه مسیر پروژه قطعی نمود.

۳. مدل دوم: یادگیری انتقالی پایه (YOLOv8n - Primary Optimized Model)

پس از مشاهده عملکرد ضعیف و کمپرازش (Underfitting) در مدل پایه، استراتژی آموزش تغییر کرد و رویکرد یادگیری انتقالی (Transfer Learning) به عنوان راحل اصلی انتخاب شد. در این مرحله، همچنان از معماری سبک YOLOv8 Nano استفاده گردید، اما با این تفاوت کلیدی که شبکه از صفر آموزش ندید؛ بلکه وزن‌های از پیش آموزش‌دیده (Pre-trained Weights) به شبکه تزریق شد تا مدل با درک پایه‌ای از اشکال و اشیاء، وارد فرآیند یادگیری دیتاست ترافیکی KITTI شود.


۳-۱. تحلیل رفتار و جهش عملکردی (بررسی منحنی‌ها)

استفاده از دانش قبلی باعث شد تا مدل از همان دوره‌های ابتدایی (Epochs) درک درستی از ماهیت وسایل نقلیه داشته باشد. دقت مدل در این مرحله با یک جهش خیره‌کننده به حدود ۸۵ درصد در شاخص mAP50 رسید. برای درک دقیق‌تر رفتار این شبکه، ۴ منحنی اصلی ارزیابی مورد تحلیل قرار گرفتند:




تحلیل منحنی Precision-Recall: همان‌طور که در نمودار بالا مشخص است، مساحت زیر منحنی (AUC) نسبت به مدل اول به شدت افزایش یافته و عدد کلی ۰/۸۵۱ را نشان می‌دهد. کلاس ماشین (Car) با دقت بسیار بالای ۰/۹۶۱ به پایداری


رسیده است که نشان از عملکرد عالی شبکه در تشخیص خودروها دارد. با این حال، هنوز در کلاس‌های اقلیت مانند عابر پیاده (Pedestrian) با دقت ۰/۷۹۲ شاهد افت زود هنگام منحنی در مقادیر بالای پوشش (Recall) هستیم.



تحلیل منحنی F1-Score: این نمودار نقطه تعادل بین دقت (Precision) و پوشش (Recall) را نشان می‌دهد. بالاترین میانگین هارمونیک برای تمامی کلاس‌ها (خط آبی ضخیم) به عدد ۰/۸۰ در آستانه اطمینان 0.347 (Confidence) رسیده است. این یعنی بهینه‌ترین حالت خروجی مدل زمانی است که حساسیت را روی ۳۴ درصد تنظیم کنیم. قله‌ی پایین‌تر برای کلاس‌هایی نظیر عابر پیاده، عدم قطعیت شبکه در تشخیص این اهداف کوچک را اثبات می‌کند.




تحلیل منحنی Precision-Confidence: این نمودار نشان می‌دهد که برای رسیدن به پیش‌بینی‌های بدون خطا، شبکه چقدر باید سخت‌گیری کند. در این مدل، شبکه برای رسیدن به دقت ۱۰۰ درصد (Precision=1.00) مجبور است آستانه اطمینان را تا عدد بسیار بالای ۰/۹۵۵ افزایش دهد. در این سطح از سخت‌گیری، شبکه تقریباً تمام عابرین پیاده را فیلتر کرده و تنها روی ماشین‌های کاملاً واضح تمرکز می‌کند.




تحلیل منحنی Recall-Confidence: این منحنی رفتار شبکه را در پیدا کردن اشیاء نشان می‌دهد. افت سریع و زود هنگام نمودار کلاس‌های اقلیت با افزایش سطح اطمینان، ثابت می‌کند که مدل در محیط‌های شلوغ، بخش زیادی از این اشیاء را با پس‌زمینه ترکیب کرده و از دست می‌دهد.

۳-۲. تحلیل خطاهای طبقه‌بندی (ماتریس‌های درهم‌ریختگی)

برای کالبدشکافی دقیق‌تر خطاهای مدل، ماتریس درهم‌ریختگی در دو حالت خام و نرمال‌شده بررسی گردید:



تحلیل ماتریس درهم‌ریختگی (شمارش مطلق): بررسی اعداد خام در این ماتریس مقیاس واقعی خطاها را آشکار می‌کند. شبکه توانسته ۲۶۹۰ خودرو (Car) و ۲۴۲ ون (Van) را به درستی تشخیص دهد. با این حال، در ستون مربوط به پس‌زمینه (Background) مشاهده می‌کنیم که تعداد قابل توجهی از اشیاء شامل ۱۶۷ ماشین، ۱۱۰ عابر پیاده و ۳۵ دوچرخه‌سوار به طور کامل توسط شبکه نادیده گرفته شده‌اند. (False Negatives)



تحلیل ماتریس نرمال شده: اگرچه مشکل تشخیص پس‌زمینه نسبت به مدل اول تا حد زیادی بهبود یافته است، اما ماتریس نرمال شده نشان می‌دهد که همچنان ۲۵ درصد از عابرین پیاده (Pedestrian) با پس‌زمینه اشتباه گرفته می‌شوند (عدد ۰/۲۵ در ستون اول). همچنین خطاهای جزئی در تفکیک ون از ماشین (۸ درصد خطا) همچنان وجود دارد.

۳-۳. نتیجه‌گیری مدل دوم: کشف چالش بیش‌برازش (Overfitting)

با وجود نتایج بسیار خوب ($mAP=85\%$) روی داده‌های اعتبارسنجی (Validation)، تست‌های عملیاتی این مدل روی تصاویر جدید اینترنتی، یک باگ مهندسی را آشکار کرد: **مدل دچار بیش‌برازش شده بود**. به دلیل استفاده از عکس‌های خام و بدون شکنجه (Augmentation)، شبکه به جای یادگیری مفهوم انتزاعی وسایل نقلیه، صرفاً زاویه دید خاص دوربین و پس‌زمینه خیابان‌های آلمان) محیط دیتاست KITTI را «حفظ» کرده بود. (Domain Shift) این کشف مهم، پایه‌گذار طراحی و تغییرات بنیادین در معماری مدل سوم گردید.

۴. مدل نهایی: معماری پیشرفته و مقابله با چالش‌ها (YOLOv8s - Advanced Model)


برای غلبه بر چالش بیش‌برازش (Overfitting)، وابستگی شبکه به پس‌زمینه تصاویر (Domain Shift) و همچنین حل مشکل عدم تعادل کلاس‌ها (Class Imbalance) که در مدل دوم کشف شد، توسعه مدل نهایی با تغییرات بنیادین در معماری و استراتژی‌های آموزش در دستور کار قرار گرفت.

۴-۱. ارتقای معماری و استراتژی‌های پیشرفته آموزش (Data Augmentation)


- **ارتقای ظرفیت شبکه:** معماری از نسخه نانو (Nano) به نسخه اسمال (Small - YOLOv8s) ارتقا یافت. افزایش تعداد لایه‌ها و رسیدن پارامترهای شبکه به بیش از ۱۱ میلیون پارامتر، ظرفیت مدل را برای درک الگوهای بصری پیچیده‌تر به شدت بالا برد.
- **تکنیک‌های Mosaic و Mixup:** برای جلوگیری از حفظ کردن خیابان‌های آلمان (دیتاست KITTI) توسط شبکه، از تکنیک‌های شکنجه عمدی داده‌ها استفاده شد. با تنظیم پارامترهای $Mosaic=1.0$ و $Mixup=0.1$ ، تصاویر به صورت ترکیبی (چهار تکه) و با شفافیت‌های متغیر به شبکه داده شدند. این مهندسی داده، مدل را مجبور کرد تا به جای تکیه بر محیط، دقیقاً روی شکل هندسی اشیاء تمرکز کند.
- **توقف زودهنگام (Early Stopping):** با تنظیم پارامتر توقف هوشمند روی ۱۰ دور ($Patience=10$)، شبکه از ادامه یافتن بی‌دلیل آموزش جلوگیری کرد و دقیقاً در نقطه طلایی بالاترین تعمیم‌پذیری متوقف شد تا بهترین وزن‌های ممکن (best.pt) ذخیره شوند.

۴-۲. تحلیل رفتار و جهش عملکردی (بررسی منحنی‌ها)


نتایج ارزیابی مدل نهایی روی داده‌های کاملاً نادیده (Test Set)، نشان‌دهنده یک پیروزی کامل مهندسی بود. دقت نهایی در شاخص mAP_{50} به عدد خیره‌کننده ۸۹.۵ درصد رسید. تحلیل ۴ منحنی اصلی، این جهش را به خوبی کالبدشکافی می‌کند:




تحلیل منحنی Precision-Recall (جهش کلاس‌های اقلیت): در این نمودار، تاثیر ارتقای معماری و رفع باگ‌های مدل قبلی به وضوح نمایان است. دقت کلاس عابر پیاده (Pedestrian) از ۰/۷۹۲ به ۰/۸۵۹ و دقت کلاس دوچرخه‌سوار (Cyclist) از ۰/۸۲۷ به ۰/۸۷۹ جهش پیدا کرد. این اعداد اثبات می‌کنند که شبکه موفق شده است ویژگی‌های ظاهری کلاس‌های کمیاب را با دقتی هم‌رده با ماشین‌ها (۰/۹۷۷) درک کند و تعادل بی‌نظیری در تشخیص تمام اشیاء ایجاد نماید.



تحلیل منحنی F1-Score (پیشرفت قطعیت مدل): در مدل نهایی، قله‌ی میانگین هارمونیک برای تمامی کلاس‌ها به عدد عالی ۰/۸۷ ارتقا یافته است. اما دستاورد مهم‌تر، جابه‌جایی آستانه اطمینان است؛ این قله اکنون در آستانه اطمینان بالاتر (۰/۴۵۳) رخ می‌دهد. این بدان معناست که مدل نهایی نه تنها دقیق‌تر است، بلکه «اعتماد به نفس» بسیار بیشتری در پیش‌بینی‌های خود دارد و در آستانه‌های سخت‌گیرانه‌تر نیز پایداری خود را حفظ می‌کند.




تحلیل منحنی Precision-Confidence: برخلاف مدل دوم که برای رسیدن به دقت ۱۰۰ درصد نیازمند آستانه ۰/۹۵۵ بود، مدل نهایی در آستانه اطمینان پایین‌تر و منطقی‌تری (حدود ۰/۹۳۱) به دقت کامل می‌رسد. همچنین نزدیک بودن و فشردگی نمودار کلاس‌های مختلف (ماشین، عابر، دوچرخه) به یکدیگر، نشان‌دهنده حل شدن مشکل کلاس‌های اقلیت و یادگیری متوازن شبکه است.




تحلیل منحنی: Recall-Confidence در این منحنی، شیب افت پوشش (Recall) بسیار ملایم‌تر از مدل‌های قبلی شده است. این یعنی حتی اگر کاربر نهایی در داشبورد نرم‌افزار، حساسیت مدل را روی اعداد بالا تنظیم کند، شبکه همچنان قادر است بخش عمده‌ای از اشیاء و انسان‌ها را بدون افت شدید عملکرد، در تصویر پیدا کند.

۴-۳. تحلیل خطاهای طبقه‌بندی (ماتریس‌های درهم‌ریختگی)

بررسی ماتریس‌های درهم‌ریختگی در مدل نهایی، تاثیر مستقیم تکنیک Mosaic را در کاهش خطاهای رایج نشان می‌دهد:



تحلیل ماتریس درهم‌ریختگی (شمارش مطلق و کاهش چشمگیر خطا): با مقایسه اعداد خام این ماتریس با مدل قبلی، قدرت یادگیری شبکه نمایان می‌شود. تعداد تشخیص‌های کاملاً صحیح ماشین (Car) به ۲۷۴۶ مورد افزایش یافته است. مهم‌تر از آن، خطای نادیده‌گرفتن اشیاء در پس‌زمینه (ستون Background) به شدت کاهش یافته است؛ به طوری که تعداد عابرین پیاده‌ی نادیده‌گرفته شده از ۱۱۰ مورد در مدل قبل به ۸۳ مورد تقلیل یافته است. این اعداد نشان می‌دهند شبکه با موفقیت توانسته اشیاء پنهان در شلوغی تصویر را استخراج کند.



تحلیل ماتریس نرمال شده (پایداری کلاس ها): مقایسه این ماتریس با مدل های قبلی نشان دهنده پایداری مطلق شبکه در محیط های واقعی است. خطای ترکیب شدن عابر پیاده با پس زمینه به ۱۹ درصد (۰/۱۹) کاهش یافته و خطای دوچرخه سواران به مرز بی نظیر ۱۳ درصد (۰/۱۳) رسیده است. همچنین تشخیص کلاس اصلی یعنی ماشین (Car) با دقت ۹۶ درصد (۰/۹۶) به صورت کاملاً بی نقص عمل می کند.

۵. توسعه رابط کاربری تعاملی وب (Streamlit Dashboard)

در پروژه های بینایی ماشین (Computer Vision)، آموزش یک مدل قدرتمند تنها نیمی از مسیر حل مسئله است. نیمه دوم و حیاتی پروژه، استقرار مدل (Deployment) و ایجاد بستری است که کاربر نهایی بتواند بدون درگیر شدن با پیچیدگی های کدنویسی، از هوش مصنوعی استفاده کند. به همین منظور، در فاز دوم پروژه یک داشبورد تعاملی تحت وب با استفاده از فریمورک Streamlit طراحی و پیاده سازی گردید.

۵-۱. معماری و قابلیت های داشبورد وب


رابط کاربری توسعه یافته، به صورت یکپارچه با بهترین وزن های به دست آمده از مدل پیشرفته (YOLOv8s) متصل شده است و قابلیت های عملیاتی زیر را در اختیار کاربر قرار می دهد:

- پردازش چندرسانه‌ای (Image & Video Inference) : کاربر می‌تواند تصاویر و یا ویدیوهای ترافیکی مد نظر خود (از جمله تصاویری که مدل پیش از این هرگز در دیتاست آموزشی ندیده است) را در سایت بارگذاری کند. هسته پردازشی در پس‌زمینه، فریم به فریم داده‌ها را تحلیل کرده و خروجی کادربندی‌شده (Bounding Boxes) را همراه با برچسب کلاس‌ها به کاربر نمایش می‌دهد.

- تنظیم پلادرنگ آستانه حساسیت (Confidence Threshold Slider): یکی از مهمترین چالش‌های عملیاتی در دنیای واقعی، نیاز به تغییر حساسیت مدل بر اساس شرایط نوری و محیطی است. در این داشبورد، یک اسلایدر تعاملی تعبیه شده است که کاربر می‌تواند آستانه اطمینان مدل را از ۰ تا ۱۰۰ درصد تغییر دهد. با این قابلیت، در محیط‌های بسیار شلوغ می‌توان حساسیت را بالا برد تا خطای مثبت کاذب (False Positives) کاهش یابد و در محیط‌های مه‌آلود یا تاریک می‌توان حساسیت را پایین آورد تا هیچ شیئی نادیده گرفته نشود.

۵-۲. بررسی عملکرد رابط کاربری در محیط عملیاتی

برای اثبات کارایی سیستم یکپارچه، مدل نهایی بر روی داده‌های تصویری دلخواه در محیط وب مورد ارزیابی قرار گرفت:



تحلیل خروجی رابط کاربری: همان‌طور که در تصویر محیط وب مشاهده می‌شود، مدل توانسته است به صورت بلادرنگ (Real-time) اشیاء موجود در تصویر را با دقت بسیار بالا تشخیص داده و برچسب‌گذاری کند. اتصال پایدار بین مدل پردازشی (Back-end) و رابط کاربری (Front-end) نشان‌دهنده موفقیت کامل عملیات استقرار (Deployment) در این فاز از پروژه می‌باشد.

۶. زیرساخت نرم‌افزاری و خودکارسازی (MLOps و Docker)

یکی از مهم‌ترین استانداردهای مهندسی در پروژه‌های مدرن هوش مصنوعی، قابلیت تکرارپذیری (Reproducibility) و اجرای مستقل از سیستم‌عامل است. در این فاز از پروژه، برای جلوگیری از تداخل پیش‌نیازها و مدیریت یکپارچه منابع، کل فرآیند آموزش، ارزیابی و رابط کاربری درون محیط ایزوله داکر (Docker) کانتینرایز (Containerize) گردید.

۶-۱. معماری سرویس‌گرا با Docker Compose

به جای اجرای یکپارچه و درهم‌تنیده کدها، از رویکرد جداسازی سرویس‌ها (Decoupling) استفاده شد. با پیکربندی فایل Compose، سه سرویس کاملاً مجزا برای پروژه تعریف گردید:

- **سرویس آموزش (Trainer):** مسئول تخصیص کامل منابع پردازنده گرافیکی (GPU) به فرآیند آموزش و مدیریت ذخیره‌سازی وزن‌های شبکه.
- **سرویس ارزیابی (Evaluator):** وظیفه بارگذاری بهترین وزن‌های ذخیره شده و تست خودکار مدل روی مجموعه داده‌های نادیده (Test Set) را بر عهده دارد.
- **سرویس رابط کاربری (Streamlit UI):** سرویس اختصاصی برای استقرار داشبورد وب، مدیریت پورت‌های شبکه و تعامل با کاربر نهایی.

۶-۲. مدیریت منابع سخت‌افزاری و دسترسی به گرافیک

با توجه به سنگین بودن محاسبات شبکه‌های عصبی پیچیده (مانند YOLOv8s با ۱۱ میلیون پارامتر)، تخصیص مستقیم کارت گرافیک به درون کانتینرهای داکر از اهمیت بالایی برخوردار بود. با استفاده از ابزارهای بومی انویدیا (NVIDIA Container Toolkit) و پیکربندی صحیح، شبکه توانست از حداکثر توان پردازشی سخت‌افزار استفاده نماید. همچنین مشکل قفل شدن فایل‌های خروجی در محیط لینوکس، با مدیریت صحیح سطح دسترسی (Ownership) بین کاربر میزبان و محیط ریشه (Root) کانتینر برطرف گردید.

۷. نتیجه‌گیری نهایی فاز دوم

فاز دوم پروژه توسعه سیستم تشخیص شیء، با موفقیت چشمگیری در تبدیل یک دیتاست خام به یک سیستم هوشمند و کاربردی به پایان رسید. مسیر طی شده در این فاز، اهمیت استفاده از استراتژی‌های علمی و مهندسی داده را در حل مسائل واقعی بینایی ماشین به اثبات رساند:

۱. **اهمیت دانش پیشین در شبکه‌های عصبی:** آموزش مدل پایه از صفر نشان داد که رسیدن به دقت قابل قبول تنها با اتکا به یک دیتاست محدود (KITTI) ، منجر به کم‌پرازش (Underfitting) و دقت بسیار پایین ۳۴ درصد می‌شود. استفاده از یادگیری انتقالی (Transfer Learning) ، این دقت را در گام اول به ۸۵ درصد ارتقا داد .

۲. **غلبه بر چالش بیش‌پرازش و حفظ کردن محیط:** با کشف ضعف مدل دوم در تعمیم‌پذیری و وابستگی شدید به پس‌زمینه تصاویر ، مدل نهایی با ارتقای ظرفیت شبکه (YOLOv8s) و اعمال تکنیک‌های پیشرفته ترکیب تصاویر (Mosaic و Mixup) آموزش دید. این استراتژی، شبکه را مجبور به یادگیری ماهیت هندسی اشیاء نمود.

۳. **حل مشکل عدم تعادل کلاس‌ها (Class Imbalance):** مدل نهایی توانست خطای تشخیص کلاس‌های اقلیت را به طرز چشمگیری کاهش دهد؛ به گونه‌ای که دقت تشخیص عابرین پیاده به ۸۵.۹ درصد و دوچرخه‌سواران به ۸۷.۹ درصد رسید.

۴. **توسعه محصول نهایی:** ثبت رکورد خیرمکننده ۸۹.۵ درصد در شاخص جامع mAP50 روی داده‌های تست، و اتصال موفقیت‌آمیز این مدل به یک داشبورد تعاملی وب، نشان‌دهنده بلوغ کامل این سیستم است.

در نهایت، پیاده‌سازی این سیستم در بستر داکر تضمین می‌کند که پروژه به عنوان یک زیرساخت نرم‌افزاری مقیاس‌پذیر، آماده استقرار در سناریوهای واقعی دنیای فناوری اطلاعات است.